

Motivacion supongamos un conjunto de variables de entrada o covariantes,  $z$ , y una salida  $x$ . La idea seria ver como depende la variable de salida  $x$  con los covariates. En general se quisiera estimar la densidad condicional  $p(x|z)$ .

A partir de los datos que son un conjunto de  $n$  pares,  $(x_i, z_i)$ , los objetivos son:

- Poder evaluar analiticamente (parametricamente?) a  $p(x|z)$ .
- Generar un conjunto de muestras  $x_j$  a partir de  $p(x|z^*)$  dado un valor del target  $z^*$ .

Buscamos un mapa que elimine de la densidad de  $x$  toda la variabilidad explicable por  $z$ . Esto es lo que hacemos cuando obtenemos  $p(x|z)$  dado un  $z^*$ .

Para encontrar ese mapa pongo dos condiciones

$$\min_{y=T(x,z)} \mathbb{E}_\pi[c(x,y)] \quad (1)$$

sujeto a que  $y$  sea independiente de  $z$ . En algun sentido diria a que no quede mas informacion de  $x$  en  $z$ .

Una vez que encuentre el  $T$  lo puedo usar para generar muestras de la condicional:

Dado un  $z^*$  y dado los datos  $\{x_i, z_i\}_{1:n}$  puedo generar las  $y_i = T(x_i, z_i)$  y luego antitransformo a  $x_i^* = T^{-1}(y_i, z^*)$  esto me daria datos posibles de la variabilidad de  $x$  dado  $z^*$ .

uedo hacer esto con el MPF-Stein? Transformo

## 1 Formulación Dual de Kantorovich

- Problema Primal

$$\min_{\pi} \int \int c(x,y) d\pi(x,y) \quad (2)$$

sujeto a que  $\pi$  tenga marginales  $\rho_1, \rho_2, \dots, \rho_K$ .

- Problema Dual

$$\max_{\{\phi_k\}_{k=1}^K} \sum_{k=1}^K \int \phi_k(x) \rho_k(x) dx \quad (3)$$

Para el caso general de  $K$  medidas:

$$\sum_{k=1}^K \phi_k(x_k) \leq c(x_1, x_2, \dots, x_K) \quad \forall (x_1, \dots, x_K) \quad (4)$$

### Interpretación

- $\phi_k(x)$ : potenciales de Kantorovich
- $\int \phi_k(x) \rho_k(x) dx$ : valor total de la masa en  $\rho_k$  evaluada con precios  $\phi_k$
- La maximización busca los precios que maximizan el beneficio total respetando las restricciones de arbitraje

## Dualidad Fuerte (Teorema de Kantorovich)

Bajo condiciones regulares:

$$\min_{\pi} \int \int c(x, y) d\pi(x, y) = \max_{\phi_1, \phi_2} \left\{ \int \phi_1(x) \rho_1(x) dx + \int \phi_2(y) \rho_2(y) dy \right\} \quad (5)$$

## 2 Kantorovich

$$\min_{\mu, \pi_k} \sum_{k=1}^K P_k \int c(x, y) \pi_k(x, y) dx dy \quad (6)$$

$$\int \pi_k(x, y) dy = \rho_k(x), \quad \int \pi_k(x, y) dx = \mu(y) \quad (7)$$

Where: -  $\mu$  is the barycenter distribution (optimization variable) -  $\pi_k(x, y)$  are the joint distributions coupling  $\rho_k$  and  $\mu$  (optimization variables) -  $P_k$  are the weights for each source distribution -  $c(x, y)$  is the cost function (squared Euclidean distance in this case) -  $\rho_k(x)$  are the source distributions - The first constraint ensures  $\pi_k$  has  $\rho_k$  as its x-marginal - The second constraint ensures  $\pi_k$  has  $\mu$  as its y-marginal

Formulación de Kantorovich - Todas las Ecuaciones

Problema Primal Relajado

Función Objetivo:

$$\min_{\mu, \pi_k} \sum_{k=1}^K P_k \int c(x, y) \pi_k(x, y) dx dy \quad (8)$$

Restricciones:

$$\int \pi_k(x, y) dy = \rho_k(x), \quad \int \pi_k(x, y) dx = \mu(y) \quad (9)$$

Problema Dual

Función Objetivo Dual:

$$\max_{\phi_k, \psi_k} \sum_{k=1}^K \int \phi_k(x) \rho_k(x) dx \quad (10)$$

Restricciones Duales:

$$\forall x, y : \quad \phi_k(x) + \psi_k(y) \leq P_k c(x, y), \quad \forall y : \sum_{k=1}^K \psi_k(y) \geq 0 \quad (11)$$

Relación entre Dual y Primal

$$Y_k(x) = x - \frac{1}{P_k} \nabla \phi_k(x) \quad (12)$$

Simplificación del Dual

Restricciones Equivalentes:

$$\forall \mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_K \end{pmatrix}, \quad \sum_{k=1}^K \phi_k(x_k) \leq \min_y \sum_{k=1}^K P_k c(x_k, y) \quad (13)$$

Función de Costo Independiente de  $y$ :

$$C(x_1, \dots, x_K) = \min_y \sum_{k=1}^K P_k c(x_k, y) \quad (14)$$

Problema Dual Simplificado:

$$\max_{\phi_k} \sum_{k=1}^K \int \phi_k(x) \rho_k(x) dx \quad (15)$$

sueto a:

$$\forall \mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_K \end{pmatrix}, \quad \sum_{k=1}^K \phi_k(x_k) \leq C(x_1, \dots, x_K) \quad (16)$$

Relación Primal-Dual para Distancia Cuadrática

Para la función de costo de distancia cuadrática, la solución óptima tiene la forma:

$$\pi_k(x, y) = \rho_k(x) \delta(y - Y_k(x)) \quad (17)$$

### 3 Implementacion

$$\min_{y_i=T(x_i, z_i)} \max_{g, f} \frac{1}{n} \sum_{i=1}^n [c(x_i, y_i) + \lambda g(y_i) f(z_i)], \quad \text{subject to} \quad \sum_{i=1}^n f(z_i) = 0, \quad \|f\| = \|g\| = 1 \quad (18)$$

Primeramente necesitamos encontrar las  $g$  y  $f$  que maximizan la funcion de costo. Para esto vamos a restringir la busqueda de las funciones  $f$  y  $g$  a espacios de dimension finita ( $\mathcal{F}$  y  $\mathcal{G}$ ). En lugar de considerar todas las funciones posibles, solo consideramos combinaciones lineales de un conjunto finito de funciones base ("features" o características).

$$f(z) = F(z)a = \sum_{j=1}^{m_z} F^j(z) a_j, \quad g(y) = G(y)b = \sum_{k=1}^{m_y} G^k(y) b_k \quad (19)$$

donde:  $F(z)$  y  $G(y)$  son vectores de funciones base predefinidas (por ejemplo, polinomios, funciones trigonométricas, kernels, etc.).  $a \in \mathbb{R}^{m_z}$  y  $b \in \mathbb{R}^{m_y}$  son los vectores de coeficientes a determinar.  $m_z$  y  $m_y$  son las dimensiones de estos espacios de características, elegidas por el usuario.

Se reemplaza  $G(y)$  por un operador ortogonal  $Q_y(y)$  que genere el mismo rango efectivo a traves de SVD,

$$\mathbf{G}_0 = \mathbf{U} \Sigma \mathbf{V}^T \quad (20)$$

donde  $G_0$  es la matriz evaluada en los puntos  $y_{0j}$ .

La cantidad de dimensiones de  $Q_y(y)$  es tal que genere gran parte de la variabilidad con  $m_y$  tal que  $\sum_k^{m_y} \sigma_k^2 > 0.99$

Se define una nueva matriz de transformación  $\mathbf{B}^y$  de tamaño  $m_y \times n_y$  que proyecta los coeficientes originales al espacio reducido y ortogonal:

$$\mathbf{B}_{jk}^y = \frac{1}{\sigma_k} \mathbf{V}_{jk}, \quad \text{para } j = 1, \dots, m_y; \quad k = 1, \dots, n_y \quad (21)$$

El nuevo operador de características ortogonales  $Q_y$  se define como:

$$Q_y(y) = G(y) \mathbf{B}^y \quad (22)$$

Entonces hemos representado al problema de maximizacion de funciones en un espacio finito y a traves de coeficientes que tienen que ser determinados a traves de la maximizacion.

Entonces ahora el problema min-max lo tenemos en  $a, b, y_l$ ,

$$\min_{\{y_i\}} \left\{ \max_{a,b} \sum_{i=1}^n c(x_i, y_i) + \lambda \sum_{h=1}^{n_z} \sum_{l=1}^{n_y} \left( \sum_{i=1}^n Q_z^h(z_i) Q_y^l(y_i) \right) a_h b_l, \quad \|a\| = \|b\| = 1 \right\} \quad (23)$$

Se puede determinar en forma explicita la maximizacion en esencia  $a$  y  $b$  se deben alinear con las primeras componentes principales a izquierda y derecha.

Nuevamente entonces hacemos SVD sobre la matriz  $\mathbf{A} = \mathbf{Q}_z^\top \mathbf{Q}_y = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$ .

Entonces terminamos en un problema de minimizacion dado por

$$\min_{\{y_i\}} \sum_{i=1}^n c(x_i, y_i) + \lambda \|A(y)\| \quad (24)$$

podemos hacer un problema de descenso de gradientes dado por:

$$y_i^{n+1} = y_i^n - \eta^n \left[ \frac{1}{n} \nabla_y c(x_i, y) \Big|_{y_i^n} + \lambda a' \nabla_y A \Big|_{y_i^n} b \right] \quad (25)$$

donde  $\nabla_y A^{hl} \Big|_{y_i^n} = Q_z^h(z_i) \sum_j \nabla G^j(y) \Big|_{y_i^n} B_{jl}^y$